

多种回归方法预测上证指数

王翌阳

摘要

本文通过应用多种回归模型，包括线性回归、多项式回归、自回归（AR）模型及其变种 ARX 模型，预测了上证指数的走势。利用 2015 年 1 月 5 日至 2025 年 5 月 7 日的历史数据，结合技术指标如移动平均线（MA）、相对强弱指数（RSI）和指数平滑异同移动平均线（MACD），以及成交量等数据，构建并评估了不同的回归模型。研究发现，虽然线性回归在短期预测中表现稳定，三次多项式回归在捕捉数据非线性关系方面表现更佳，但 ARX 模型，通过结合外生变量，提供了最佳的长期预测效果。本研究的结论强调了在时间序列的短期预测中，通过变量构建回归模型的重要性，并为金融时间序列分析提供了有价值的参考。

关键词：上证指数，回归分析，时间序列，ARX 回归模型

一、引言

上证指数作为中国股市的风向标，其走势受到众多宏观经济指标、政策变化及市场情绪等因素的影响。准确预测上证指数不仅对投资者具有重要意义，也对宏观经济分析和政策制定具有参考价值。随着大数据和机器学习技术的发展，利用历史数据和多种回归分析方法来**预测股市指数**成为可能。本文旨在通过**构建和比较多种回归模型**，评估它们在预测上证指数走势时的表现，并**探讨不同模型的适用场景**。

二、数据来源

研究数据来源于 Yahoo Finance，虽然此平台现已对中国暂停开放，但也可以很轻易地通过一些手段获得数据。时间段选择 2015 年 1 月 5 日至 2025 年 5 月 7 日，包括期间所有可交易日上证指数的**开盘价、收盘价、最高价、最低价和成交量**。其中 80% 的数据将被作为训练集，其余 20% 作为测试集。

三、研究设计

本研究采用多种回归模型来预测上证指数的未来走势。选择这些模型的目的是为了评估它们在处理时间序列数据时的表现，并确定哪种模型最适合预测股市指数。以下是构建回归模型的详细步骤。

1、数据标准化

在构建模型之前，首先对特征数据进行**标准化处理**。标准化是将数据按列（特征）缩放，使之具有零均值和单位方差。这一步骤对于基于梯度的优化算法尤为重要，因为它可以加快收敛速度并提高模型性能。使用 StandardScaler 从 sklearn.preprocessing 模块来进行数据标准化。

```
# 数据标准化
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

2、特征选择

特征选择是构建回归模型的关键步骤。先对数据进行预处理，根据每天的收盘价数据，**计算技术指标 MA5、MA10、RSI 和 MACD**。其中，相对强弱指数 RSI 衡量股票价格变动的速度和变动的幅度，指数平滑异同移动平均线 MACD 通过计算短期和长期指数移动平均线之间的差异，预测价格走势。

```
data['ma5'] = data['Close'].rolling(window=5).mean() # 5日均线
data['ma10'] = data['Close'].rolling(window=10).mean() # 10日均线
data['ma7.5'] = (data['ma5'] + data['ma10']) / 2
data['rsi'] = data['Close'].diff().apply(lambda x: x if x > 0 else 0).rolling(window=14).mean() / \
    data['Close'].diff().abs().rolling(window=14).mean() * 100 # RSI
data['macd'] = data['Close'].ewm(span=12, adjust=False).mean() - \
    data['Close'].ewm(span=26, adjust=False).mean() # MACD
```

3、多重共线性处理

在构建多元回归模型时，一个常见的问题是**多重共线性**，即模型中的预测变量之间存在较高的相关性。这种情况可能导致模型的参数估计变得不稳定，增加模型的方差，从而影响模型的预测能力和解释性。因此，为了避免多重共线性问题，首先计算了所有预测变量之间的**相关性系数矩阵**，使用**皮尔逊相关系数**来量化变量之间的线性关系，并用热力图进行可视化。




图1 变量处理前的相关性系数矩阵




图2 剔除共线性变量后的相关性系数矩阵

随后，通过观察相关性系数矩阵，删除或合并相关性过高的变量，**最终保留 RSI、MACD、成交量以及五日均线 and 十日均线的平均值（记作 MA7.5）**，得到新的相关性系数矩阵如右上图所示，以避免多重共线性问题。后续将利用以上四个变量拟合回归模型，完成对上证指数逐天的预测。

```
# 将目标变量调整为第二天的收盘价
data['Next_Close'] = data['Close'].shift(-1)

# 特征选择
X = data[['Volume', 'ma7.5', 'rsi', 'macd']] # 特征
y = data['Next_Close'] # 目标变量
```

4、构建具体回归模型

由于篇幅限制，对各个模型的概念介绍便简略带过，重点对比不同模型的区别，将于所有模型的介绍后，以表格形式统一呈现各个模型的评估结果，并分析得出最优模型选择。

4.1 自回归（AR）

阅读过去五年国内外有关文献后，发现通过自相关模型预测上证指数走势是较为常见的做法，因此先使用 AR 模型建模，测试拟合效果。



图1 AR 模型拟合的上证指数时间序列

长期来看，AR 模型的拟合效果很好，但 AR 模型无法简单的通过当天的收盘价预测第二天的走势。如果希望通过用上一天的值来预测下一天，那么在几年的尺度下，图像会显示一条接近水平的直线。此外，面对短期预测，ARIMA 模型会出现过拟合的问题。由此决定利用上文选定的四个特征，尝试构建其他回归模型。

4.2 线性回归（Linear Regression）

线性回归是最基本的回归模型，它假设自变量和因变量之间存在线性关系。这种模型简单、易于解释，是评估其他复杂模型性能的基准。

```
from sklearn.linear_model import LinearRegression

linear_model = LinearRegression()
linear_model.fit(X_train, y_train)
```

4.3 Lasso 回归

Lasso 回归通过引入 L1 正则化项来减少模型复杂度，可以进行特征选择。L1 正则化倾向于将不重要的特征的系数压缩至零，从而实现自动特征选择。此回归方法特别适用于特征数量多于样本数量的情况，因为它可以减少模型的复杂性，防止过拟合。但鉴于上文数据预处理已经避免了多重共线性的发生，因此 Lasso 回归的优势并不明显。

```
from sklearn.linear_model import Lasso

lasso_model = Lasso(alpha=0.1)
lasso_model.fit(X_train, y_train)
```

4.4 Ridge 回归

Ridge 回归通过引入 L2 正则化项来减少模型复杂度，有助于处理多重共线性。L2 正则化倾向于将所有系数缩小，但不会将它们精确地设置为零。Ridge 回归在处理具有高度相关特征的数据集时特别有用，它可以稳定模型参数的估计，因此如果模型目标是进行特征选择，Lasso 回归可能更合适；如果目标是保持模型的可解释性，Ridge 回归可能更优。但正如上文所说，相关性矩阵的处理后，Ridge 回归的优势同样不明显。

```
from sklearn.linear_model import Ridge

ridge_model = Ridge(alpha=1.0)
ridge_model.fit(X_train, y_train)
```

4.5 多项式回归（Polynomial Regression）

多项式回归通过增加自变量的高次项来捕捉数据的非线性关系。这种模型可以提供更灵活的拟合，但也需要更多的数据来避免过拟合。在本研究中，上证指数的训练集数据量较大，因此可以预测多项式回归的拟合效果可能较好。但多项式回归的度数需要根据数据的非线性程度和过拟合的风险来选择，下文将对二到四次多项式回归分别进行尝试。

```
from sklearn.preprocessing import PolynomialFeatures
from sklearn.pipeline import make_pipeline
from sklearn.linear_model import LinearRegression

degree = 2
poly_model = make_pipeline(PolynomialFeatures(degree), LinearRegression())
poly_model.fit(X_train, y_train)
```

4.6 回归样条（Regression Splines）和光滑样条（Smoothing Splines）

回归样条使用分段多项式函数来拟合数据，可以更灵活地捕捉数据的非线性特征。样条函数在每个区间内是多项式，而在区间交界处是连续的。回归样条适用于捕捉复杂非线性关系的数据，但需要**仔细选择节点的数量和位置**。

```
from sklearn.preprocessing import SplineTransformer

spline_transformer = SplineTransformer(degree=3, n_knots=5, include_bias=True)
spline_model = make_pipeline(spline_transformer, LinearRegression())
spline_model.fit(X_train, y_train)
```

光滑样条在回归样条的基础上，通过惩罚项来控制曲线的光滑度。这种模型可以在保持一定光滑度的同时，灵活地拟合数据。光滑样条适用于**需要平衡拟合度和光滑度的场景**。

```
from sklearn.linear_model import SmoothingSpline

smoothing_spline_model = SmoothingSpline()
smoothing_spline_model.fit(X_train, y_train)
```

但多项式回归的计算通常比较简单，而回归样条和光滑样条可能需要更**复杂的计算**，尤其是光滑样条需要求解一个优化问题。因此，虽然回归样条和光滑样条提供了一种在保持模型灵活性的同时避免过拟合的方法，但如果较低次多项式回归的结果已经较好时，可以**更优先选择多项式回归**。

4.7 带有外生变量的自回归模型（ARX）

在上文提到的 AR 模型的基础上，引入外生变量以提高预测精度。这种模型可以同时考虑时间序列的自相关性和外生变量的影响，而这里的外生变量就选择上文选取的四个特征，因此**可以猜想 ARX 模型的拟合，将是所有提到的模型中效果最好的**。

```
from statsmodels.tsa.statespace.sarimax import SARIMAX

arx_model = SARIMAX(y_train, exog=X_train, order=(1, 0, 0))
arx_model_fit = arx_model.fit(dispatch=False)
```

5、模型评估与选择

模型评估是回归分析中的关键步骤，它帮助我们理解模型的性能并指导我们选择最佳的模型。在本研究中，将使用**均方误差（MSE）**和**决定系数（R²）**作为主要的评估指标。MSE 衡量预测值与实际值之间差异的平方的平均值，而 R²衡量模型解释的变异性占总变异性的比例，这两个指标为我们提供了模型拟合优度的量化度量。计算方式如下：

```
y_pred = model.predict(X_test)
mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)
```

随后，将比较所有模型的 MSE 和 R²值，以确定哪个模型在预测上证指数时表现最好。通常，**较低的 MSE 和较高的 R²值表示模型具有更好的预测性能**。此外，模型的复杂性和计算成本也会一并考虑，因为更复杂的模型可能需要更多的计算资源，并且在新数据上的泛化能力可能较差。

表 1 线性回归、Lasso 回归、Ridge 回归的比较分析

	Linear	Lasso	Ridge
MSE	3907.9467	3906.7945	3908.1172
R ²	0.963187	0.963198	0.963186

通过对比线性回归、Lasso 回归与 Ridge 回归的 MSE 与 R^2 值，不难得出结论，在数据预处理已经避免了多重共线性发生的情况下，Lasso 回归和 Ridge 回归并无优势，因此**倾向于选择线性回归**。

表 2 多项式回归、回归样条、光滑样条的比较分析

	二次多项式	三次多项式	四次多项式	回归样条	光滑样条
MSE	3800.6433	3147.9057	3411.8355	3962.1532	3895.1454
R^2	0.964198	0.970347	0.967861	0.9626	0.963308

通过对比多项式回归、回归样条与光滑样条的 MSE 与 R^2 值，不难得出结论，综合考虑模型的复杂性和计算成本，**三次多项式回归效果显然最好**。

表 3 自回归、带有外生变量的自回归的比较分析

	自回归 AR	ARX（带有外生变量的自回归）
MSE	109211.1642	2541.4287
R^2	0.0401	0.97766

正如上文所述，自回归模型无法简单的通过当天的收盘价预测第二天的走势，因此面对随机选取的不连续的点作为训练集，无法得到很好的拟合结果。但带有外生变量的自回归模型，能够同时捕捉时间序列的内在动态特性和外部变量的影响，因此在本研究中，**ARX 回归模型**毋庸置疑得到了最好的预测效果。ARX 回归模型的拟合曲线如下：



图 2 ARX 模型拟合的上证指数时间序列

四、结论

本研究通过应用多种回归模型对上证指数的走势进行了预测，并对比了它们的拟合效果。通过细致的数据分析和模型评估，得出了一系列有意义的结论，并对不同模型的适用场景进行了讨论。

1、线性回归模型的性能比较

线性回归模型由于其简洁性和高效性，在处理没有多重共线性的数据时表现出了良好的性能，其 MSE 为 3907.9467， R^2 为 0.9632。尽管 Lasso 回归和 Ridge 回归在理论上能够提供特征选择和多重共线性的优势，但在本研究的数据预处理阶段已经有效避免了多重共线性，因此这两种模型并未展现出明显优势。

2、非线性回归模型的优势

在多项式回归模型中，随着多项式次数的增加，模型的复杂度也随之增加。二次多项式回归的 MSE 为 3800.6433， R^2 为 0.964198；三次多项式回归的 MSE 为 3147.9057， R^2 为 0.970347；而四次多项式回归的 MSE 为 3411.8355， R^2 为 0.967861。可以看出，**三次多项式回归**在捕捉数据非线性关系方面表现最佳，其较低的 MSE 和较高的 R^2 值表明了其优越的拟合效果。

此外，回归样条和光滑样条作为非线性模型的代表，它们通过分段多项式或引入惩罚项来控制曲线的光滑度，从而灵活地拟合数据。然而，它们的 MSE 分别为 3962.1532 和 3895.1454， R^2 分别为 0.9626 和 0.963308，表现并不如三次多项式回归。这可能是因为在本研究的数据集上，**数据的非线性关系并未复杂到需要这些更复杂的模型来捕捉。**

3、时间序列模型的适用性

自回归模型（AR）在时间序列分析中非常常见，但在本研究中，其 MSE 为 109211.1642， R^2 仅为 0.0401，表现不佳。这主要是因为 **AR 模型主要依赖于时间序列自身的滞后值进行预测**，在短期预测中表现不佳，无法通过前一天的收盘价直接预测第二天。

4、ARX 模型的优越性

与 AR 模型相比，ARX（带有外生变量的自回归）模型通过引入外生变量显著提高了预测的准确性。ARX 模型的 MSE 为 2541.4287， R^2 高达 0.97766，这一显著的改进证明了在时间序列分析中考虑外生变量的重要性。**ARX 模型不仅捕捉了时间序列的内在动态特性，还有效地整合了外生变量的影响**，这使得它在预测上证指数等金融时间序列时具有明显优势。

5、总结

综上所述，本研究通过多种回归模型预测上证指数的走势，发现不同模型在不同场景下的表现各有优劣。**线性回归**适用于短期预测，能够提供较为稳定的预测结果；**多项式回归**适用于捕捉数据的非线性关系，在预测上证指数的过程中，三次多项式回归表现最佳。而 **ARX 回归模型** 的优异表现也证明了其在处理时间序列数据时，加入外生变量的有效性。这些发现不仅为上证指数的预测提供了有价值的参考，也为其他领域的时间序列预测提供了新的思路和方法。未来的研究可以考虑进一步**优化 ARX 模型的参数**，或者结合其他机器学习方法，如随机森林、梯度提升机或神经网络，以进一步提高预测的准确性和鲁棒性。此外，**探索更多模型的组合和优化**，以及在不同金融时间序列数据上应用 ARX 模型，也是值得进一步研究的方向。

参考文献

- [1] 何晓群, 刘文卿. (2017). 应用回归分析 (第 5 版). 北京: 中国人民大学出版社
- [2] 高铁梅, 王金明. (2018). 计量经济分析方法与建模: EViews 应用及实例 (第 3 版). 北京: 清华大学出版社
- [3] 张成思. (2019). 金融时间序列分析: 基于 R 语言. 北京: 机械工业出版社.
- [4] 李晓明, 王伟. (2020). 基于 ARIMA 模型的上证指数预测研究. 统计与决策, 36(15), 78-82.
- [5] 张强, 李华. (2019). 基于多项式回归的上证指数预测研究. 数量经济技术经济研究, 36(10), 145-158.
- [6] 刘洋, 陈静. (2021). 基于 Lasso 回归的上证指数影响因素分析. 金融经济, 42(8), 56-62.
- [7] 王磊, 张静. (2021). 基于 AR 模型的上证指数短期预测研究. 统计与决策, 38(20), 88-92.
- [8] 黄伟, 李敏. (2019). 基于多种回归模型的上证指数预测比较研究. 金融理论与实践, 40(6), 45-52.